UAX Universidad Alfonso X el Sabio

Comandos Bash

BIOINFORMÁTICA 26-27

Grado en Biomedicina

UAX

1.- Wildcards

```
mi_primer_string="Este es mi primer string"
echo $mi_primer_string
mkdir bash
cd bash
touch mi_prueb1.txt prueba20.txt prueba3.txt pruebaaaaa4.txt prueba_no_mas.txt reporte.pdf reporte_40.txt
ls
# Todos los archivos que empiecen por prueba
ls -l prueba*
# Todos los archivos que acaben en .txt
ls -l *\.txt
# Todos los archivos que contengan la palabra prueba con tres caracteres cualquiera antes
ls -l ???prueb*
# Todos los archivos que contengan 1 o 3 en su nombre
ls -l *[13]*\.txt
# Todos los archivos que contengan dos números seguidos en su nombre
ls -l *[0-9][0-9]*
ls -l [a-z]*\.pdf
```

2.- Operadores I/O

```
# Crear un archivo llamado generos_bacterias
echo -e "\nRickettsia\nOrientia\nWolbachia\nHolospora\nEhrlichia\nOdysella\nTectibacter" > generos_bacteria.txt
cat generos_bacteria.txt
# Añadimos un nombre más
echo -e "Escherichia\n" >> generos_bacteria.txt
cat generos_bacteria.txt
# Ordenamos el contenido del archivo
(sort < generos_bacteria.txt) > generos_bacteria_sorted.txt
cat generos_bacteria_sorted.txt
```

3.- Variables de entorno

Comando	Función
`HOME`	Guarda el directorio `/home/usuario`. Cambia de acuerdo al usuario. En mi computador guarda `/Users/j`.
`PATH`	Lista de directorios separados por " : " que le indican a la shell dónde buscar archivos ejecutables.
`SHELL`	Guarda el directorio de la shell predeterminada en el sistema.
`~/.bashrc`	Este script posee configuraciones para la shell que se leen cada vez que se abre una nueva ventana de Terminal en Linux.
`~/.zshrc`	Mismo funcionamiento que `~/.bashrc` pero en sistemas operativos MacOS modernos.
`printenv`	Muestra todas las variables de estado de la shell.

```
which Bash
echo $PATH
echo $HOME
echo $SHELL
printenv
```



4.- Patrones de búsqueda

METACHARACTERS AND BEHAVIOURS:

Character	Description / What it matches	Example
\	Marks next character as a **special character** or a **literal**.	'**\n**' matches **newline character**. '****' matches "****"
^	**Start of line**/string	
$	**End of line**/string	
.	Matches any **single character** except "\n"	
*	Matches **0 or more** copies (as many as possible) *of *preceding character or subexpression*.	**zo*** matches "**z**" and "**zoo**"
+	Matches **1 or more** copies *.	'**zo+**' matches "**zo**" and "**zoo**", but not "**z**"
?	Matches **0 or 1** copies (as few as possible) *.	"**do(es)?**" matches "**do**" or "**does**"
{*n*}	Matches exactly *n* times * or between n AND m) if {*n*,*m*} is called	'**o{2}**' matches the two o's in "**food**", but not the o in "**bob**".
[*xyz*]	A **character set** - matches any enclosed characters	'**[abc]**' matches the '**a**' in "**plain**"
[a-z]	Matches a **range of characters**.	'**[a-z]**' matches all lowercase characters
[^*xyz*]	A **negative character set** - matches any character **not** enclosed.	'**[^fo]**' matches the '**d**' in "**food**" '**[^0-9]**' = any non-number char
x|*y*	Either *x* **or** *y*.	"**gray|grey**" matches "**gray**" or "**grey**"
(*pattern*)	A **marked subexpression** - matches *pattern* and captures the match. NOTE: (?:*pattern*), (?=*pattern*) and (?!*pattern*) are variations	"**gr(a|e)y**" matches "**gray**" or "**grey**" (& is more efficient)

SPECIAL CHARACTERS:

Char	Match	Char	Example
\s	any **white space** character (space, tab, form feed, etc)	\n	**new line** char
\S	matches any **non-white space** character. Equivalent to [^ \f\n\r\t\v].	\r	**carriage return**
\b	Matches a **word boundary**. *eg: 'er\b' matches the 'er' in "never" but not in "verb"*	\t	**tab** character
\B	Matches a **nonword boundary**. *eg: 'er\B' matches the 'er' in "verb" but not in "never".*	\f	Matches a **form-feed** character.
\w	Matches any **word character** including underscore. *Equivalent to '[A-Za-z0-9_]'.*	\d	Matches a **digit character**. *Equivalent to [0-9].*
\W	Matches any **nonword character**. *Equivalent to '[^A-Za-z0-9_]'.*	\D	Matches a **nondigit character**. *Equivalent to [^0-9].*
\c*x*	Matches the **control character** indicated by *x*. **eg**: \cM matches a Control-M or carriage return character. *x* must be in the range of A-Z or a-z, else c is taken as a literal 'c'.	*num*	Matches *num*, where *num* is a positive integer. A reference back to captured matches. For example, '(.)\1' matches two consecutive identical characters.

Grep

grep [opciones] pattern [archivo]

Versión	Descripción
`-G` o `--basic-regexp`	Interpreta los patrones como regex básicas (BREs). Es las versión estándar de la herramienta
`-E` o `--extended-regexp`	Interpreta los patrones como regex extendidas (EREs)
`-F` o `--fixed-strings`	Interpreta los patrones como string fijos, no como regex
`-P` o `--perl-regexp`	Interpretar los patrones como expresiones regulares compatibles con Perl (PCREs)

Flag	Descripción
`-e "patron(es)"` o `--regexp="patron(es)"`	Busca los patrones especificados como argumento y los caracteres `\n` separan un patrón del siguiente
`-f archivo` o `--file=archivo`	Busca los patrones de un archivo, uno por línea
`-i` o `--ignore-case`	Hace que la regex no sea sensible a mayúsculas o minúsnuclas. La regex "abc" coincide con el patrón "AbC"
`-v` o `--invert-match`	Invierte el sentido de coincidencia, para seleccionar líneas que no coinciden con el patrón
`-w` o `--word-regexp`	Selecciona solo las líneas que contengan coincidencias que formen palabras completas
`-x` o `--line-regexp`	Seleccione solo los patrones que coincidan exactamente con toda la línea

Opción	Descripción
`-c` o `--count`	Se imprime el número de líneas que coinciden con un patrón para cada archivo de entrada. Con la opción `-v` se cuentan las líneas que no coinciden
`--color`	Se colorean los patrones, líneas coincidentes o de contexto, nombres de archivo, y números de línea
`-L` o `--files-without-match`	Se imprime el nombre de los archivos de entrada que no coinciden con el patrón de búsqueda
`-l` o `--files-with-matches`	Se imprime el nombre de los archivos de entrada que coinciden con el patrón de búsqueda
`-m num` o `--max-count=num`	La búsqueda del patrón se detiene luego de que se cumpla con el número de coincidencias especificadas en num
`-o` o `--only-matching`	Se imprime solo las partes coincidentes con el patrón de búsqueda de las líneas, con cada parte separada por una nueva línea
`-q` o `--quiet`	No se imprime nada en la terminal
`-s` o `--no-messages`	Suprimir los mensajes de error de los resultados que se imprimen en la terminal

Opción	Descripción
`-H` o `--with-filename`	Imprime el nombre de archivo por cada coincidencia. Este es el valor predeterminado cuando hay más de un archivo para buscar
`-h` o `--no-filename`	Suprima el prefijo de los nombres de archivo. Este es el valor predeterminado cuando solo hay un archivo para buscar
`-n` o `--line-number`	Imprime el número de línea de cada coincidencia antes del patrón
`-T` o `--initial-tab`	Se verifica de que el primer carácter del contenido de la línea tiene en una tabulación

Opción	Descripción
`-A num` o `--after-context=num`	Imprime el número de líneas que se ubican después de las coincidencias con el patrón de búsqueda
`-B num` o `--before-context=num`	Imprime el número de líneas que se ubican antes de las coincidencias con el patrón de búsqueda
`-C num` o `--context=num`	Imprime el número de líneas que se ubican antes y después de las coincidencias con el patrón de búsqueda

Opción	Descripción
`-r` o `--recursive`	Para cada operación que se aplique al directorio, lea y procese todos los archivos en ese directorio, de forma recursiva
`--exclude=glob`	Omitir cualquier archivo de línea de comandos con un sufijo de nombre que coincida con el patrón global, utilizando coincidencias con *wildcards*
`--include=glob`	Buscar solo archivos de línea de comandos con un sufijo de nombre que coincida con el patrón global, utilizando coincidencias con *wildcards*

- grep --version
- grep --help
- ls
- grep -i “computadora” poema.txt > mi_primera_regex.txt
- grep -i -E -v “computadora|Roberto” poema.txt
- grep -E “a|e” poema.txt
- grep -w “se” poema.txt
- grep -E -c “^.*$” poema.txt
- grep -c “?” poema.txt

Sed

sed ‘s/texto_a_buscar/texto_a_reemplazar’ <fichero_a_reemplazar >fichero_nuevo

- sed ‘s/o/O/g’ <poema.txt >poemaO.txt
- echo “que es esto” | sed ‘s/q/Q’
- sed -i ‘s/t/T/g’ poemaO.txt
- sed -I ‘/rapero/s/f/F/g’ poemaO.txt
- sed -i '9,27 s/Que/Como/g' poemaO.txt
- sed -e 's/u/U/g' -e 's/r/R/g' poemaO.txt

Cut

Opción	Descripción
`-f LIST` o `--fields=LIST`	Se selecciona especificando un campo/columna, conjunto de campos, o rango de campos. También imprime cualquier línea que no contenga un carácter delimitador, a menos que se especifique la opción `-s`
`-b LIST` o `--bytes=LIST`	Se selecciona especificando un byte, conjunto de bytes, o rango de bytes
`-c LIST` o `--characters=LIST`	Se selecciona especificando un carácter, conjunto de caracteres, o rango de caracteres
`-d` o `--delimiter`	Se especifica un delimitador que se utilizará en lugar del "TAB", que es el predeterminado
`--complement`	Cuando se usa esta opción, el corte se realiza en todos los bytes, caracteres o campos excepto el/los seleccionados
`-s` o `--only-delimited`	De forma predeterminada, cut imprime las líneas que no contienen ningún carácter delimitador. Cuando se usa esta opción, no se imprimen líneas que no contienen delimitadores
`--output-delimiter`	El comportamiento predeterminado de cut es utilizar el delimitador de entrada como delimitador de salida. Esta opción permite especificar un delimitador de salida diferente

Forma	Descripción
`N`	El campo, byte, o carácter N, comenzando por 1
`N-`	Desde el campo, byte, o carácter N, hasta el final de la línea
`N-M`	Desde el campo, byte, o carácter N al M
`-M`	Desde el primer campo, byte, o carácter hasta el M

- cut --version
- paste students.txt grades.txt > notas_final.txt
- cut -f 1 notas_final.txt
- #cut -f 1 -d "," archivo #Esto en caso de que hubiese algún separador en la columna

- #cut -f 1-2 notas_final.txt

Sort

Opción	Descripción
`-b` o `--ignore-leading-blanks`	Ignorar los espacios en blanco iniciales
`-g` o `--general-numeric-sort`	Comparar según el valor numérico general
`-r` o `--reverse`	Invertir el resultado de las comparaciones
`-u` o `--unique`	Permite eliminar las líneas repetidas
`-c` o `--check`	Compruebe si el archivo de entrada ha sido ordenado
`-k POS1[,POS2]` o `--key=POS1[,POS2]`	Ordena considerando campos o columnas específicas. POS toma la forma `F[.C]`, donde F es el número de campo y C la posición del carácter en el campo; ambos empiezan en 1

- sort --version
- sort students.txt #si queremos especificar por columna usamos -k
- # -g elimina los duplicados ej: sort -g -k 2 archivo.txt

Taller1.- Búsqueda de patrones en un archivo FASTA

```
# Opción 1
# Señales de inicio
grep -E -c "TATAAA|TATAAT" Ecoli_genome.fna
# Señales de terminación
grep -E -c "A{5,}" Ecoli_genome.fna

### Opción 2
# Señales de inicio
grep -E "TATAAA|TATAAT" Ecoli_genome.fna | wc -l
# Señales de terminación
grep -E "A{5,}" Ecoli_genome.fna | wc -l

# Búsqueda de sitios de unión a FT.
grep -E -o "AT..TC|ACA.TT|TTTC..A" Ecoli_genome.fna | wc
# Búsqueda de subsecuencias
grep -E "TACA.+AAAAAT" Ecoli_genome.fna
```

Taller 2.- Búsqueda de patrones en un archivo multi FASTA

```
# Opción 1
grep -E -c ">" Ecoli_CDS.fna

# Opción 2
grep -E ">" Ecoli_CDS.fna | wc -l

# >lcl|CP018245.1_cds_API18666.1_1 [locus_tag=BFL23_00005] [protein=Thr operon leader peptide] [protein_id=API18666.1]
[location=190..273] [gbkey=CDS]
grep -E -o "^>lcl\|[A-Z]{1,2}.{6}\.[0-9]" Ecoli_CDS.fna | sed -r 's/>lcl\|//g' > ecoli_headers_cds.txt
grep -n "AGCGGTGCAAAACCAGGTACA" Ecoli_CDS.fna

# Extraer las descripciones de las proteínas y guardarlos
grep -E -o "\[protein=.+" Ecoli_CDS.fna | sed -r -e 's/\].*//g' -e 's/\[protein=//g' > ecoli_description_cds.txt

# Unir los headers con las descripciones
paste ecoli_headers_cds.txt ecoli_description_cds.txt > prueba.txt

#>API18666.1 Thr operon leader peptide [Escherichia coli]
grep -E -o ">API[0-9]{5}\.[0-9]" Ecoli_protein.faa | sed -r 's/>//g' > ecoli_proteinID.txt
grep -E -o "FKAARS" Ecoli_protein.faa
```

Taller 3.- Búsqueda de sitios de restricción

grep -n "GAATTC" Ecoli_genome.fna
grep -n "CCCGGC" Ecoli_genome.fna

Taller 4.- Editar un archivo pdf

```
# Cambiar las CYS por CYX
sed 's/CYS/CYX/g' 3c5x.pdb > 3c5x_cyx.pdb
# Cambiar las CYX por CYS  de las primeras 579 líneas del archivo
sed '1,579 s/CYX/CYS/g' 3c5x_cyx.pdb > 3c5x_cyx_cys.pdb
# Eliminar las líneas 4-579
sed '4,579d' 3c5x_cyx_cys.pdb > 3c5x_cyx_cys_clean.pdb
# Eliminar información sobre puentes de hidrógeno
grep -E -n "^HETATM" 3c5x_cyx_cys_clean.pdb
# Después de buscarlas las eliminamos
sed '3711,3882d' 3c5x_cyx_cys_clean.pdb > 3c5x_no_HETATM.pdb
# Buscamos los puentes di sulfuro para eliminarlos
grep -E -n "^CONECT" 3c5x_no_HETATM.pdb
sed '3711,3818d' 3c5x_no_HETATM.pdb > 3c5x_no_HETATM_CONN.pdb
# Miramos cuántas cadenas tiene nuestra proteína
grep -n "TER" 3c5x_no_HETATM_CONN.pdb
```

Taller 5.- Empleo de BLAST en local

sudo apt-get install ncbi-blast+
blastp -query PBP1-Saureus.fasta -subject PBP1.fasta -out result.out
blastp -query PBP1-Saureus.fasta -subject PBP1.fasta -outfmt “6”
makeblastdb -in PBP1.fasta -dbtype ‘prot’ -out PBP1
Realiza la misma búsqueda pero ahora empleando la base de datos que acabas de crear
#Descarga la base de datos de SwissProt de https://ftp.ncbi.nlm.nih.gov/blast/db/
wget https://ftp.ncbi.nlm.nih.gov/blast/db/swissprot.tar.gz
Prueba a ejecutar la búsqueda de tu secuencia con swissprot y que te devuelva solo 5 resultados
Opciones

Tabla 1. Opciones generales de Blast

option	type	default value	description and notes
db	string	none	BLAST database name.
query	string	stdin	Query file name.
query_loc	string	none	Location on the query sequence (Format: start-stop)
out	string	stdout	Output file name
evalue	real	10	Expect value (E) for saving hits
subject	string	none	File with subject sequence(s) to search.
show_gis	flag	N/A	Show NCBI GIs in report.
num_descriptions	integer	500	Show one-line descriptions for this number of database sequences.
num_alignments	integer	250	Show alignments for this number of database sequences.
html	flag	N/A	Produce HTML output
gilist	string	none	Restrict search of database to GI's listed in this file. Local searches only.
negative_gilist	string	none	Restrict search of database to everything except the GI's listed in this file. Local searches only.
entrez_query	string	none	Restrict search with the given Entrez query. Remote searches only.
best_hit_overhang	real	none	Best Hit algorithm overhang value (recommended value: 0.1)
best_hit_score_edge	real	none	Best Hit algorithm score edge value (recommended value: 0.1)
dbsize	integer	none	Effective size of the database
searchsp	integer	none	Effective length of the search space
import_search_strategy	string	none	Search strategy file to read.
export_search_strategy	string	none	Record search strategy to this file.
parse_deflines	flag	N/A	Parse query and subject bar delimited sequence identifiers (e.g., gi|129295).
num_threads	integer	1	Number of threads (CPUs) to use in blast search.
remote	flag	N/A	Execute search on NCBI servers?